

线性回归

一种用于查找变量之间关系的统计技术。在 ML 中，用于查找特征和标签之间的关系。

线性回归方程

代数术语：定义为 $y' = b + w_1x_1$ ，其中：

- y' 是预测标签。
- b 是模型的偏差，与直线代数方程式中的 y 轴截距概念相同。在 ML 中，偏差有时称为 w_0 ，是模型的形参，在训练时计算得出。
- w_1 是特征的权重，与线性代数方程中的斜率 k 的概念相同。权重是模型的形参，在训练时计算得出。
- x_1 是一个特征。

在训练期间，模型会计算出可生成最佳模型的权重和偏差。

具有多种特征的模型

更复杂的模型可能依赖于多项特征，每项特征都有一个单独的权重，表示为：

$$y' = b + w_1x_1 + w_2x_2 + w_3x_3 + \cdots + w_nx_n。$$

损失函数

损失是一种数值指标，可以描述模型的预测与实际情况的偏差程度，用于衡量模型预测与实际标签之间的距离。

训练模型的目的是尽可能降低损失，使其达到最低值。

损失距离

损失侧重于值之间的距离，而非方向，所以损失没有负值，在计算时需要移除符号。

有两种常见的移除符号的方法：

- 计算实际值与预测值之差的绝对值。
- 计算实际值与预测值之差的平方。

损失类型

主要有五种类型的损失：

损失类型	定义	公式
L_1 损失	预测值与实际值之间的差的绝对值之和。	$\sum \text{实际值} - \text{预测值} $
平均绝对误差 (MAE)	一组 N 个示例的平均 L_1 损失。	$\frac{1}{N} \sum \text{实际值} - \text{预测值} $
L_2 损失	预测值与实际值之间的差的平方之和。	$\sum (\text{实际值} - \text{预测值})^2$

损失类型	定义	公式
均方误差 (MSE)	一组 N 个示例的平均 L_2 损失。	$\frac{1}{N} \sum (\text{实际值} - \text{预测值})^2$
均方根误差 (RMSE)	均方根 (MSE) 的平方根。	$\sqrt{\frac{1}{N} \sum (\text{实际值} - \text{预测值})^2}$

在某些情况下，MAE 和 RMSE 等损失指标可能更可取，因为它们往往更易于人工解读，且使用与模型预测值相同的比例来衡量误差。

MAE 和 RMSE 的差异可能非常大，MAE 表示平均预测误差，而 RMSE 是预测误差的典型数值，并且受较大误差的影响更大。

MSE 的数学属性通常会使优化更顺畅，而 RMSE 通常用于将误差恢复为与标签相同的单位。

在同时处理多个示例时，建议对所有示例的损失求平均值。

选择损失

使用 MAE 还是 MSE 取决于数据集以及处理预测的方式。

数据集中的大多数特征值通常处于一个明确的范围内，若超出典型范围，则会被视为离群点。

选择最佳损失函数时，需要考虑如何处理离群值，通常 MSE 会使模型更接近离群点，而 MAE 会更接近大多数数据点。

梯度下降

梯度下降法是一种数学技巧，可迭代地找到能使模型产生最低损失的权重和偏差。

模型开始训练时，如果需要初始化，会把权重和偏差随机化为接近于零的值，然后重复以下步骤：

1. 使用当前权重和偏差计算损失。
2. 确定可减少损失的权重和偏差的移动方向。
3. 将权重和偏差沿可减少损失的方向移动少量（即**学习速率**）距离。
4. 返回第一步，重复此过程，直到模型无法进一步减少损失为止。

模型收敛和损失曲线

通过查看损失曲线，可以确定模型是否收敛。

收敛和凸函数

线性模型的损失函数会生成凸面，根据这一属性，当模型收敛时，我们就知道已经找到了最合适的权重和偏差。

模型几乎找不到可最大限度减少损失的确切权重和偏差，但可以找到非常接近这些值的值。

超参数

超参数是控制训练方向的变量，如学习速率、批次大小、周期等。

超参数是受我们控制的量，参数是模型计算出的量。

学习速率

学习速率是一个浮点数，用于影响模型收敛的速度。过低，收敛所需时间过长；过高，模型无法收敛，而是在最合适的权重和偏差附近跳动。

我们应当选择一个既不太高也不太低的学习速率，以让模型快速收敛。

学习速率决定了在梯度下降过程中，对权重和偏差所做的更改幅度。

批次大小

批次大小是指模型在更新权重和偏差之前处理的示例数量。

有两种常见技术，可以在不查看数据集中每个示例的情况下，获得正确的平均梯度，然后更新权重和偏差。： **随机梯度下降**和**小批量随机梯度下降**。

随机梯度下降法（SGD）

在每次迭代中仅使用一个示例。在迭代次数足够多的情况下，SGD 可以正常运行，但**噪声**非常大。

噪声是指，训练期间导致损失在迭代过程中增加而非减少的变化。

在整个损失曲线中都可能产生噪声，并不是在接近收敛时才有。

小批次随机梯度下降法（小批次SGD）

全批次和 SGD 之间的折中方案。

对于 N 个数据点，批次大小可以是 $1 \sim N$ 的任意数字。模型会随机选择每个批次中包含的示例，求梯度的平均值，然后更新权重和偏差。

小批量大小的行为类似于 SGD，大批量大小行为类似于全批量梯度下降。

周期数

在训练期间，一个周期是指模型对训练集中的每个示例处理一次。训练通常需要多个周期。

一般来说，训练周期数越多，模型效果越好，但训练时间越长。当训练周期过多时，可能会导致过拟合。