

导数和微分

对于每个参数，如果我们把这个参数增加或减少一个**尽可能小**的量，就可以知道损失会以多快的速度增加或减少。

对于一个定义域和值域都是 $\mathbb{R}$ 且输入和输出都是标量的函数 f ，如果其导数存在，则这个极限被定义为：

$$f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$$

如果 $f'(a)$ 存在，则称 f 在 a 处是可微的。如果 f 在一个区间内的每个数上都是可微的，则此函数在此区间中是可微的。

$$f'(x) = y' = \frac{dy}{dx} = \frac{df}{dx} = \frac{d}{dx} f(x) = Df(x) = D_x f(x)$$

其中 $\frac{d}{dx}$ 和 D 是微分运算符，表示微分操作。有以下规则对常见函数求微分：

- $DC = 0$ (C 是一个常数)。
- $Dx^n = nx^{n-1}$ (幂律， n 是任意实数)。
- $De^x = e^x$ 。
- $D \ln(x) = \frac{1}{x}$ 。

为了微分一些复合函数，假设函数 f, g 都是可微的， C 是一个常数，有以下法则：

- 常数相乘法则： $\frac{d}{dx}[Cf(x)] = C \frac{d}{dx}f(x)$ 。
- 加法法则： $\frac{d}{dx}[f(x) + g(x)] = \frac{d}{dx}f(x) + \frac{d}{dx}g(x)$ 。
- 乘法法则： $\frac{d}{dx}[f(x)g(x)] = f(x) \frac{d}{dx}[g(x)] + g(x) \frac{d}{dx}[f(x)]$ 。
- 除法法则： $\frac{d}{dx} \left[\frac{f(x)}{g(x)} \right] = \frac{g(x) \frac{d}{dx}[f(x)] - f(x) \frac{d}{dx}[g(x)]}{[g(x)]^2}$ 。

偏导数

设 $y = f(x_1, x_2, \dots, x_n)$ 是一个具有 n 个变量的函数， y 关于第 i 个参数 x_i 的偏导数为：

$$\frac{\partial y}{\partial x_i} = \lim_{h \rightarrow 0} \frac{f(x_1, \dots, x_{i-1}, x_i + h, x_{i+1}, \dots, x_n) - f(x_1, \dots, x_i, \dots, x_n)}{h}$$

为了计算 $\frac{\partial y}{\partial x_i}$ ，可以把其他变量看作常数，然后计算 y 关于 x_i 的导数。对于偏导数的表示，以下是等价的：

$$\frac{\partial y}{\partial x_i} = \frac{\partial f}{\partial x_i} = f_{x_i} = f_i = D_i f = D_{x_i} f$$

梯度

把一个多元函数对其各个变量的偏导数按顺序排列，就得到了该函数的**梯度**向量。

令 f 为输入是 n 维向量 $\mathbf{x} = [x_1, x_2, \dots, x_n]^\top$ 、输出是标量的函数，则其相对于 $\mathbf{x}$ 的梯度是一个包含 n 个偏导数的向量：

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \left[\frac{\partial f(\mathbf{x})}{\partial x_1}, \frac{\partial f(\mathbf{x})}{\partial x_2}, \dots, \frac{\partial f(\mathbf{x})}{\partial x_n} \right]^\top$$

在没有歧义时，通常用 $\nabla f(\mathbf{x})$ 表示。

假设 $\mathbf{x}$ 为 n 维向量，在微分多元函数时通常会使用以下规则：

- 对于所有 $\mathbf{A} \in \mathbb{R}^{m \times n}$ ，都有 $\nabla_{\mathbf{x}} \mathbf{A} \mathbf{x} = \mathbf{A}^\top$
- 对于所有 $\mathbf{A} \in \mathbb{R}^{n \times m}$ ，都有 $\nabla_{\mathbf{x}} \mathbf{x}^\top \mathbf{A} = \mathbf{A}$
- 对于所有 $\mathbf{A} \in \mathbb{R}^{n \times n}$ ，都有 $\nabla_{\mathbf{x}} \mathbf{x}^\top \mathbf{A} \mathbf{x} = (\mathbf{A} + \mathbf{A}^\top) \mathbf{x}$
- $\nabla_{\mathbf{x}} \|\mathbf{x}\|^2 = \nabla_{\mathbf{x}} \mathbf{x}^\top \mathbf{x} = 2\mathbf{x}$

对于任意矩阵 $\mathbf{X}$ ，都有 $\nabla_{\mathbf{X}} \|\mathbf{X}\|_F^2 = 2\mathbf{X}$ 。

链式法则

链式法则可以用于微分复合多元函数。

对于单变量函数：假设 $y = f(u)$ 和 $u = g(x)$ 都是可微的，根据链式法则：

$$\frac{dy}{dx} = \frac{dy}{du} \frac{du}{dx}$$

当函数具有任意数量的变量时：假设可微分函数 y 有变量 $u_1, u_2, \dots, u_m$ ，其中每个可微分的函数 u_i 都有变量 $x_1, x_2, \dots, x_n$ （注意， y 是 $x_1, x_2, \dots, x_n$ 的函数），对于任意 $i = 1, 2, \dots, n$ ，由链式法则可知：

$$\frac{\partial y}{\partial x_i} = \frac{\partial y}{\partial u_1} \frac{\partial u_1}{\partial x_i} + \frac{\partial y}{\partial u_2} \frac{\partial u_2}{\partial x_i} + \dots + \frac{\partial y}{\partial u_m} \frac{\partial u_m}{\partial x_i}$$