

概要

代价被分成两个部分的和，分别由两个函数计算而来：一个是基于近似线性模型推导出的显性模型，另一个是代表模型自由误差的黑盒模型。

线性是好处理的，所以先利用近似线性的显式方法得到梯度，再把这个梯度与模型自由算法得到的精确梯度比较，二者之间的差异会被用来修正后续基于梯度的更新。

引入

本文提及的算法用于解决：线性模型加一个较小的未知非线性扰动。

基于学习的控制算法可以被分成两类：模型自由和模型基础。

模型自由无需使用显式动力学形式，就可以解决一些难以模型化的动态问题。但是，模型自由算法需要大量数据来得到一个优化策略，导致其在物理系统下不可取。

模型基础使用显式动力学形式解决问题。因为使用了模型，模型基础算法需要比模型自由算法更少的数据，来得到一个优化策略。但当实际情况过于复杂而难以模型化或模型类别不够时，模型基础算法就不适用了。

本文发明的方法结合了模型自由和模型基础的算法，以在二次代价下，得到一个控制非线性方程的最优化策略。

代价由模型基础算法和模型自由算法两个部分组成：模型基础算法有一个可分析的式子，而模型自由算法是一个黑盒。

在计算梯度时，会用模型基础部分的梯度，加上一个由模型自由部分维护的修正参数。

背景：二次代价的非线性最优控制

本文所研究的动力系统是非线性的，表示为：

$$x_{t+1} = Ax_t + Bu_t + h(x_t, u_t)$$

其中， $x_t \in \mathbb{R}^n$ 表示状态， $u_t \in \mathbb{R}^p$ 表示控制的输入， $A \in \mathbb{R}^{n \times n}$, $B \in \mathbb{R}^{n \times p}$, $h: \mathbb{R}^n \times \mathbb{R}^p \rightarrow \mathbb{R}^n$ 且 $h(0, 0) = 0$ 。

h 无法用显式方法描述，但是它是一个非常小的扰动，可以用残差 r 相关的平滑度常数 L_r 来量化。

目标是找到一个线性状态的回归控制 $u_t = -Kx_t$ ，从而最小化代价 $C: \mathbb{R}^{p \times n} \rightarrow \mathbb{R}$ ， C 被定义为：

$$C(K) = \mathbb{E}_{x_0 \sim D} \left(\sum_{t=0}^{\infty} x_t^\top Q x_t + u_t^\top R u_t \right)$$

其中 $Q \in \mathbb{R}^{n \times n}$, $R \in \mathbb{R}^{p \times p}$ 为正定矩阵， x_0 是初始状态，且 x_0 从固定分布 D 中抽取。

当系统中，用于修正偏差的非线性部分 $h \equiv 0$ 时，此时的代价 $\hat{C}$ 被称为**二次代价**。我们将最小化 $\hat{C}$ 的点标记为 $\hat{K}^*$ ，最小化 C 的点标记为 K^* 。

设定的框架

在非精确的模型（即动力学方程的线性模型）上进行策略优化，以此降低模型自由策略梯度方法的复杂度，从而将原本的策略优化问题转化为复合优化问题，将模型信息融入策略优化的过程。

策略优化的综合优化视角

我们把代价函数 C 分成了两个部分: $C(K) = \hat{C}(K) + r(k)$, 其中 $\hat{C}$ 是二次代价, r 是定义为 $r \triangleq C - \hat{C}$ 的残差。

最小化 C 是一个具有 $\underset{x \in \mathbb{R}^n}{\text{minimize}} f(x)$ 形式的无约束优化问题, 其中 $f = \hat{f} + r$ 。

我们称 $\nabla f(x)$ 为准确梯度, $\nabla \hat{f}(x)$ 为模型梯度, $f(x)$ 的最优值记为 f^* , 使 f 最优的解记为 x^* , 记使 $\nabla \hat{f}(x) = 0$ 的点为 $\hat{x}^*$ 。

有以下假设:

1. 函数 f 满足 PL 条件, 即存在 $\mu > 0$, 对于所有 x , 满足:

$$\frac{1}{2} \|\nabla f(x)\|^2 \geq \mu(f(x) - f^*)$$

2. 残差映射 r 是 L_r 光滑的, 即 ∇r 是 $Lipschitz$ 连续的。

3. $\nabla f(x)$ 可以通过 n 次函数求值计算得出, 其中 n 是 x 的维度。 $\nabla \hat{f}$ 有闭式表达式。

一个基于模型利用的复合优化算法

在迭代时, 会把 x 更新为 $x - t\Delta(x)$ 。

算法一中, 在进行迭代时, 会使用 $\nabla \hat{f}$, 同时利用恒定补偿量 δ 来更新 $\nabla \hat{f}$, 从而保证其在迭代时的可靠性。

对于一个复合函数 $f = \hat{f} + r$, 我们定义补偿模型梯度映射 $\tilde{g} \triangleq \nabla \hat{f} + \delta$ 在 $\tilde{x}$ 处进行补偿, 此时的补偿量是一个常数:

$$\delta \triangleq \nabla f(\tilde{x}) - \nabla \hat{f}(\tilde{x}) = \nabla r(\tilde{x})$$

模型梯度映射 $\nabla \hat{f}$ 可以被视作是零补偿的补偿模型梯度映射 $\tilde{g}$ 。

因为假设 2 中确定残差映射 r 是光滑的, 所以当 $\tilde{x}$ 接近于 x 时, $\nabla r(\tilde{x})$ 将会接近于 $\nabla r(x)$ 。因此, 补偿模型梯度 $\tilde{g}(x) = \nabla \hat{f}(x) + \nabla r(\tilde{x})$ 将会接近于 $\nabla f(x) = \nabla \hat{f}(x) + \nabla r(x)$ 。

通过假设 3 可以得出, 补偿常量 $\delta \triangleq \nabla f(\tilde{x}) - \nabla \hat{f}(\tilde{x}) = \nabla r(\tilde{x})$ 可以在 n 次求解中得出。

模型基础的更新: $x_{j+1}^{(i)} = x_j^{(i)} - \eta \tilde{g}^{(i)}(x_j^{(i)})$ 。

模型自由的更新: $x_1^{(i+1)} = x_{N_i}^{(i)} - \eta \nabla f(x_{N_i}^{(i)})$ 。其中 N_i 表示第 i 次获取补偿常量后, 经过了 N_i 次迭代, 回溯线搜索才失败。

主要结果

当使用精确梯度进行梯度下降的更新时, 本文算法和普通算法没区别。所以, 主要研究的是, 补偿模型梯度映射 $\tilde{g}$, 也就是研究模型基础算法部分。

改进后的回溯线搜索

因为补偿模型梯度映射替代了精确梯度映射, 所以在某些情况下, 若不改变补偿模型的部分, 回溯线搜索可能无法终止 (如 $f(x) = (x - 2)^2, \tilde{g}(x) = 2x$, 总会有 $f(x - \eta \tilde{g}(x)) \geq f(x) > f(x) - \alpha \eta \|\tilde{g}(x)\|^2$, 此时无法找到满足条件的 η)。

为确保回溯线搜索过程中，可以找到符合条件的 η ，即算法最终会终止，设置了下界 η_{min} ：当 $\eta \leq \eta_{min}$ 时，认为回溯线搜索失败了。初始的 η 被标记为 η_{max} 。最终返回的 $\eta \in (\eta_{min}, \eta_{max})$ 。

改进后的回溯线搜索只用在模型基础部分，模型自由部分仍然使用一般的回溯线搜索。

除了回溯线搜索无法终止的情况，还可能出现无法退出模型基础的部分（即梯度下降过程中，每一次改变的幅度过少，最终在极限情况下收敛到一个并没有达到线性最优解的地方），即代价始终无法收敛到最优。所以，需要正确选取初始值 η_{max} ，但这通常是困难的。

充分下降条件

点 x_+ 被称为 f 在 x 的充分下降条件，则对于一些 $t > 0$ ，有：

$$f(x_+) < f(x) - t\|\nabla f(x)\|^2$$

对于一般的梯度下降，下一个状态 x 满足 *Armijo* 条件，那么，那么 x 一定是充分下降条件。

但对于补偿模型梯度映射而已，就没有这个必然关系，因为判断 *Armijo* 条件用的是补偿模型梯度，而充分下降条件用的是真实梯度。

命题 1： 假设使用补偿模型梯度映射时，回溯线搜索在 x 成功了，并且 $\tilde{g}$ 满足：

$$\|\nabla f(x) - \tilde{g}(x)\| \leq \frac{1-\gamma}{\gamma} \|\tilde{g}(x)\|$$

其中 $\gamma \in (0, 1)$ 。那么，更新的点 $x_+ = x - \eta\tilde{g}(x)$ 是 f 在 x 处的充分下降条件。

定义 $e(x) \triangleq \|\nabla f(x) - \tilde{g}(x)\|$ 表示补偿模型梯度映射 $\tilde{g}$ 在 x 处的偏差。

根据命题 1 我们可以知道：在 $e(x)$ 很小的时候，回溯线搜索可以保证使用补偿模型梯度映射更新时得到的是充分下降。因此，可以通过核查 $e(x)$ 来判断梯度下降是否是充分下降的。

但由于计算 ∇f 的代价过高，建议不要直接计算 $e(x)$ 。

可以构建一个上界序列 $\{\bar{e}_j\}$ 满足 $\bar{e}_j \geq e(x_j)$ ，其中 $j = 1, \dots, N$ ， $\bar{e}_j$ 代替 $e(x_j)$ 。我们可以用以下方式构建序列：

$$\begin{aligned}\bar{e}_1 &= 0 \\ \bar{e}_{j+1} &= L_r \|x_{j+1} - x_j\| + \bar{e}_j\end{aligned}$$

定理 1： 定义序列 $\{x_j\}_{j=1}^N$ 表示 $x_{j+1} = x_j - \eta_j \tilde{g}(x_j)$ 。假设回溯线搜索全部成功，对于一个固定的 $\gamma \in (0, 1)$ ，有：

$$\bar{e}_j \leq \frac{1-\gamma}{\gamma} \|\tilde{g}(x_j)\|$$

那么 x_{j+1} 都是满足充分下降条件的。

模型基础策略的改进

充分进行梯度下降后，模型基础策略下的次优性差距会以几何级数方式递减。

命题 2： 假设函数 f 的每个状态都是充分下降的，那么：

$$f(x_{N+1}) - f^* \leq (1 - 2\mu\alpha\gamma^2\eta_{min})^N (f(x_1) - f^*)$$

其中 N 是相邻两次模型自由迭代间进行模型基础迭代的次数。

本算法模型基础算法中，相对误差减少量为 $(1 - 2\mu\alpha\gamma^2\eta_{min})^N$ ，而相对误差减少量代表了模型基础策略的改进程度。

看起来， N 越大，相对误差减少量越小——但一般这是不正确的。因为如果想让 N 变大，要么减小 μ_{min} 来防止回溯线搜索的失败，要么减小 γ 来让充分下降条件更容易达成，而这两个因素的减小都会使相对误差减少量变大。

一个更新方向映射 Δ 被称为**有界更新方向**，则存在 $\kappa_{min} \in (0, 1), \kappa_{max} > \kappa_{min}$ ，使得：对于任何 x 和任何有界步长 $\eta \in (\eta_{min}, \eta_{max})$ ，满足：

$$x_+ = x - \eta \Delta(x)$$

$$\kappa_{min} \|\Delta(x)\| \leq \|\Delta(x_+)\| \leq \kappa_{max} \|\Delta(x)\|$$

当 $\tilde{g}(x)$ 和 $\nabla f(x)$ 非常接近时，算法可能会一直停留在模型基础部分中。为了给算法的迭代次数设置下限，我们需要限定每次迭代时 $\tilde{g}$ 的变化量，通过使用有界更新方向来实现。

定理 2：令 x_1 表示刚刚开始模型基础策略的迭代。假设 $\tilde{g}$ 是一个有界更新方向的映射，且 $\tilde{g}(x_1) \neq 0$ ，那么在回溯线搜索成功且满足充分下降条件的情况下， N 满足：

若 $\kappa_{max} \neq 1$ ，那么

$$\log |\kappa_{max}^N - 1| + N \log \frac{1}{\kappa_{min}} \leq \log \frac{1 - \gamma}{\gamma \eta_{max} L_r} + \log |\kappa_{max} - 1|$$

若 $\kappa_{max} = 1$ ，那么：

$$\log N + N \log \frac{1}{\kappa_{min}} \leq \log \frac{1 - \gamma}{\gamma \eta_{max} L_r}$$

显然，不等式的左侧关于 N 单调递增， N_{min} 表示满足上式的最大的 N 。

我们可以保证最少在这 N_{min} 次合法迭代中，算法取得了充足的改进。

不等式的右侧关于 L_r 单调递减，因此想让 N_{min} 变大，就需要较小的 L_r 。

在动力系统几乎是线性的时候， L_r 会变得很小，此时算法在模型基础部分迭代的次数就会增加。

函数评估次数

在达到统一改进效果的前提下，模型基础策略需要的函数评估次数少于模型自由策略的。

若目标函数是强凸且光滑的，那么梯度下降中，连续两次迭代 $i, i + 1$ 对应的函数值满足：

$$f(x_{i+1}) - f^* = \rho(f(x_i) - f^*)$$

其中， ρ 是收敛比。

在 N 次迭代后，相对误差减少量由 $\phi \triangleq \frac{f(x_N) - f^*}{f(x_0) - f^*} = \rho^N$ 决定。

用 $\frac{|\log \phi|}{N}$ 来表示每次迭代中取得的进展。当满足上述条件时，可以用 $|\log \rho|$ 来衡量，此时与 N 无关了。

每次函数评估所取得的进展被定义为 $\frac{|\log \phi|}{mN}$ ，其中 m 表示每次迭代中执行的函数评估次数。

通过假设 3 我们可以知道：计算 $\nabla f(x)$ 的函数评估次数是 n ，计算 $\nabla \hat{f}(x)$ 的函数评估次数是 0。

在回溯线搜索的子程序中，函数评估次数的最大值 m_{max} ，是满足 $\beta^{m-1} \eta_{max} \leq \eta_{min}$ 的最小整数 m 。因此：

$$m_{max} = \lceil \frac{\log(\frac{\eta_{min}}{\eta_{max}})}{\log \beta} + 1 \rceil$$

因此，函数评估次数的最大值只取决于回溯线搜索的参数。

在模型基础策略中，相对误差减少量为 $(1 - 2\mu\alpha\gamma^2\eta_{min})^N$ ，因此每次函数评估所取得的进展的下界为：

$$\frac{|\log(1 - 2\mu\alpha\gamma^2\eta_{min})|^N}{m_{max}N} = \frac{|\log(1 - 2\mu\alpha\gamma^2\eta_{min})|}{m_{max}}$$

当回归线搜索的参数和 γ 固定时，这个下界是一个定值。

当 f 是 L_f 光滑的时候，模型自由策略的收敛率 $\rho = 1 - \frac{\mu}{L_f}$ 。根据假设 3，模型自由策略的函数评估次数最少为 n ，包含计算精确梯度所需的 n 次评估和回溯线搜索中使用的额外评估次数。

因此，对于模型自由策略而言，每次函数评估所取得的进展的上界为：

$$\frac{|\log \rho|}{n} = \frac{|\log(1 - \frac{\mu}{L_f})|}{n}$$

当问题的维度 n 足够大时，上述模型基础策略的下界会大于模型自由策略的上界。因此，在实现相同的优化效果的情况下，本文算法使用的函数评估次数会少于只使用模型自由策略的算法。

数值实验

GC 指代的是梯度补偿算法。

在两种不同场景下，将 GC 与别的方法进行比较：

1. $\hat{f}$ 和 r 都是凸二次函数（ $f = \hat{f} + r$ 是凸且光滑的）。
2. 目标函数是上文所提到的 C 函数， $\hat{f}$ 未 $\hat{C}$ （ C 是非凸且局部光滑的）。

二次函数

考虑二次函数 $\hat{f}, r: \mathbb{R}^n \rightarrow \mathbb{R}$ ，表达式为 $\hat{f}(x) = \frac{1}{2}c_1x^\top Px$ 和 $r(x) = \frac{1}{2}c_2(x - c_3)^\top Q(x - c_3)$ ，其中 P, Q 都是正定矩阵。

为了保证矩阵 P 是正定矩阵，我们随机生成其平方根 $P^{\frac{1}{2}}$ ，其中每个元素均独立地从标准高斯分布中抽取，然后再通过公式 $P = P^{\frac{1}{2}}P^{\frac{1}{2}}$ 计算得到矩阵 P 。

矩阵 Q 通过谱分解随机生成，谱半径为 10。

令 $c_1 = 1, c_2 = c_3 = 0.1, n = 4, L_r = c_2 = 0.1, \alpha = 0.3, \beta = 0.5, \eta_{max} = 1, \eta_{min} = 0.005$ 。




Figure 1: Comparison among the convergence of (a) the GC algorithm with $\gamma = 0.6$, (b) the GC algorithm with $\gamma = 0.9$, and (c) the model-free method in [18] for quadratic functions. For the GC algorithm, the iterations in the model-free regime are indicated in blue, and the ones in the model-based regime are indicated in red. When γ was chosen appropriately, the GC algorithm used fewer function evaluations than the model-free method because it used relatively inexpensive model-based iterations to make progress.

上图中，(a)(b) 的结果出自 GC 算法，(c) 出自其他算法。蓝色代表是模型自由方法，红色代表模型基础方法。

扩展后的 LQR 问题

矩阵 A, B 随机生成，每个元素均独立地从标准高斯分布中抽取。

为了简化问题，非线性扰动 h 只和系统状态 x 有关： $h(x) = \frac{\ell x}{1-0.9 \sin x}$ ，其中 $\ell = 0.01$ 。

代价函数中， $Q = 2I, R = I, n = 4, p = 3$ 。

$\alpha = 0.3, \beta = 0.5, \eta_{max} = 1, \eta_{min} = 0.05$ 。

在扩展后的 LQR 问题中，难以获得 L_r 的确切值，因此我们把它当作超参数，记录多个相关数据并找到最优结果。

计算梯度

线性系统中的代价函数 $\hat{C}$ 的梯度可以通过解析方法计算得出，即 $\nabla \hat{C}(K) = 2E_K \Sigma_K$ ，其中 $E_K = (R + B^\top P_K B)K - B^\top P_K A, \Sigma_K = \mathbb{E}_{x_0 \sim D} \sum_{t=0}^{\infty} x_t x_t^\top$ 。矩阵 P_K 是 *Lyapunov* 方程的解：

$$A_K^\top P_K A_K - P_K + Q + K^\top R K = 0$$

其中， $A_K = A - BK$ 。

对于非线性系统中的代价函数 C ，我们通过零阶梯度估计方法计算出 $\nabla C(K)$ ，而 C 则通过有限时域经验成本进行近似。

$$C_{emp}^T(K) \triangleq \mathbb{E}_{x_0 \sim D} \left(\sum_{t=0}^T x_t^\top Q x_t + u_t^\top R u_t \right)$$

其中 D 在 n 个不同值 $x_0^{(1)}, x_0^{(2)}, \dots, x_0^{(n)}$ 上服从均匀分布。

$T = 50$ ，零阶梯度估计中施加的扰动大小（采样半径） $r = 0.001$ 。

结果

γ 和 L_r 的影响

γ 和 L_r 的选择会影响符合充分下降条件的难度。但当 η_{min} 过大时，二者的影响就没那么大了。此时，在大部分时候，GC 算法中，在进入模型基础部分没多久后，就会退出，所以二者的影响就没有那么大了。

η_{min} 的影响

当 η_{min} 变小的时候，GC 算法会在模型基础阶段停留更长的时间。

η_{min} 过大或者过小都会导致函数评估次数的增加：小了，会增加每次迭代所需的函数评估次数；大了会增加修正补偿的次数。

η_{min} 的选择应该平衡修正补偿的次数和每次迭代所需的函数评估次数。

总结

本文提供了一个结合模型基础和模型自由的框架，用于最优控制。

在框架中，把最优控制问题转化为复合优化问题，且该问题由两个部分组成：一个是模型基础部分，其显示表达式可以通过动力系统的近似模型获得；一个是残差部分，用于捕捉未知的建模误差。

为了解决这个复合优化问题，我们开发了混合梯度算法：利用近似模型的梯度信息，并间歇性通过模型自由算法来更新补偿机制。

理论分析和数据实验都证明，在达到同样的优化程度时，本文介绍的算法使用的函数评估次数少于纯粹使用模型自由的算法。